Качество и понятность кода

Оценка: 3 балла из 3.

Метрика качества

0.96794 в лидерборде: +1 доп. балл за точность, согласно критериям оценивания.

Работа с обучающими данными

Есть однако большая проблема: валидация (test_generator) делается также с аугментациями (на основе train_datagen). Так не должно быть. Представьте, что одну модель вы обучили на слабых аугментациях, другую на сильных. Если валидация делается с аугментациями, то модель с сильными аугментациями покажет более низкую точность на валидации. Если же делать валидацию нормально, без аугментаций, то все может быть наоборот — и выяснится, что модель, обученная на сильных аугментациях, обучилась лучше. Поскольку валидация влияет на выбор моделей и гиперпараметров, важно делать ее без аугментаций.

Оценка: 1 балл из 3.

Работа с архитектурой модели

Вы сравнивали 3 модели: Xception, ResNet50V2 и EfficientNetB5. Но сравнение, как мне кажется, проведено не совсем корректно. В процессе сравнения у Xception вы указывали параметр trainable = False. В коде, где вы работали с другими моделями (ResNet50V2 и EfficientNetB5) я такого параметра не увидел. Конечно нельзя сравнивать 2 модели, одна из которых заморожена, а две другие нет.

Но если предположить, что модели ResNet50V2 и EfficientNetB5 вы также замораживали, то все равно сравнение некорректно. Замороженная модель — это фактически модель, обученная на совсем другой задаче (imagenet). Ее на файн-тюнить под задачу распознавания автомобилей, то есть размораживать и обучать, и только тогда проявится ее потенциал. А вы сравниваете замороженные модели друг с другом. Такое сравнение очень ненадежно.

Может быть конечно я неверно понял, и работая со всеми тремя моделями вы сначала их замораживаете, а потом постепенно размораживаете. Но тогда точность получается нереалистично низкой: всего 82%, 73% и 79% на разрешении 320х320, или у вас использовалось боле низкое разрешение, но опять-таки вы об этом не написали. Вам надо было подробнее написать, по какому алгоритму вы сравнивали модели, чтобы можно было понять, корректно такое сравнение или нет. Но я готов поверить, что все-таки сравнение проводилось корректно, а я вас неверно понял.

И наконец, вы добавляете скрытый полносвязный слой, но не обосновываете такой выбор. Почему один слой, почему не 0, не 2 или 3? Если посмотреть современные работы по сверточным сетям, то там практически никогда скрытый полносвязный слой не используется.

И еще: не совсем понятно почему в процессе сравнения с другими моделями сеть Хсерtion показывает точность 82% (хотя указан параметр trainable = False), а в следующем разделе в процессе обучения всего 68% после 5 эпох.

Оценка: 2 балла из 3.

Работа с процессом обучения

Вы делаете файн-тюнинг сети, постепенно размораживая слои. Но опять-таки я должен признать, что такой решение вы никак не обосновываете. Почему бы не разморозить изначально всю сеть? Вдруг точность окажется выше? Согласно критериям оценивания, нужно было выбрать оптимальный алгоритм обучения, основываясь либо на нескольких экспериментах (их можно проводить с низким размером картинки для ускорения), либо на научных статьях или статьях их интернета. Вы же ни на чем не основываетесь в своем выборе. Оценка: 1 балл из 3.

Работа с процессом инференса

У вас делается ТТА, хотя я бы рекомендовал делать его немного другим способом, не просто по 5 предказаний на каждую картинку. Сделав 5 предсказаний сравните их – если они все совпали,

значит данный пример легкий. А если нет — значит надо продолжить TTA на данном примере. И кроме того, судя по коду, TTA делается у вас неправильно: test_sub_generator возвращает изображения без аугментаций, поэтому все 5 предсказаний будут идентичны. Оценка: 0 баллов из 3.

Создание работающего прототипа

Этого пункта у вас не нашел.

Сумма: 3+1+1+2+1 = 8 баллов