Эта переменная нигде не используется.

```
print('Распаковываем картинки')
for data_zip in ['train.zip', 'test.zip']:
    with zipfile.ZipFile(DATA_PATH+data_zip,"r") as z:
    z.extractall(PATH)
```

Это можно было бы записать проще (работает только в IPython-средах):

```
!unzip ../input/train.zip -d {PATH}
!unzip ../input/test.zip -d {PATH}
```

 Кол-во фото в трейне может не хватить для хорошего обучения модели нейронной сети, поэтому будем применять различные виды аугментации данных

Вообще аугментации применяют даже тогда, когда доступно очень много изображений.

Если мы делаем аугментации, то почему не использовать RandomCrop?

```
test_generator = train_datagen.flow_from_directory(
```

У вас валидация делается с аугментациями. Так не должно быть. Представьте, что одну модель вы обучили на слабых аугментациях, другую на сильных. Если валидация делается с аугментациями, то модель с сильными аугментациями покажет более низкую точность на валидации. Если же делать валидацию нормально, без аугментаций, то все может быть наоборот. Поскольку валидация влияет на выбор моделей и гиперпараметров, важно делать ее без аугментаций.

➤ Также надо быть внимательнее с командой "from tensorflow.keras.applications import EfficientNetB7", при этом модель обучается не корректно и не позволяет достичь хороших показателей. Нужно использовать устаревшие методы, такие как "import efficientnet.tfkeras as efn" (с последним выводом возможно я ошибаюсь, не было достаточно времени удостовериться в этом на 100%).

Может быть проблема в том, что вы делили значения пикселей на 255?

```
train_datagen = ImageDataAugmentor(
    rescale=1/255,
```

Дело в том, что EfficientNetB7 из модуля keras.applications принимает на вход значения пикселей от 0 до 255, а нормализация делается уже внутри модели.

Почти все, кто выполняет этот проект, добавляют скрытый полносвязный слой и слой batchNorm в голову сети. И не было еще почти ни одной работы, где сравнивалась бы голова со скрытыми слоями и BN и без них. Вдруг без них лучше?

```
checkpoint = ModelCheckpoint('best_model.hdf5' , monitor = ['val_accuracy'] ,
verbose = 1 , mode = 'max')
```

Здесь надо добавить save\_best\_only=True, иначе модель будет сохраняться каждую эпоху независимо от точности.

Обратите внимание на эти параметры. С таким маленьким размером батча эпоха занимает 1849 шагов, значит за 1 эпоху learning rate умножается на 0.9^18.49 = 0.14. Если он был 9е-4, то станет примерно 1е-4 после первой эпохи и примерно 2е-5 после второй, и так далее. К третьей эпохе он уменьшится настолько, что сеть перестанет обучаться.

```
EPOCHS = 4 # эксперименты показали, что такого количества эпох будет достаточно
```

Возможно именно из-за того, что LR у вас уменьшается слишком быстро, и эпохи после 4-й уже не оказывают никакого влияния. Вообще на этом датасете сети можно обучать десятки эпох при более правильно выбранных параметрах.

```
predictions_tta = []
for _ in range(EPOCHS):
    predictions_tta.append(model.predict(sub_generator, verbose=1))
    sub_generator.reset()
```

В sub\_generator у вас из аугментаций только сдвиг и horizontal\_flip. Сдвиг оказывает мало влияния на функционирование сверточных сетей, а у horizontal\_flip всего 2 возможных состояния. Стоило добавить больше аугментаций в sub\_generator. Но по крайней мере у вас они есть. Многие начинают делать ТТА вообще без аугментаций в sub\_generator и после этого делает вывод, что ТТА бесполезен и не дает прироста точности.

Можно еще делать так: сделать сначала 10 попыток на каждом изображении, а затем делать дополнительные попытки на тех изображениях, в которых результат остался спорным.

Экспериментальным путем выведено, что наиболее эффективной предобученной моделью является EfficientNet начиная с версии 3 и выше. Мной использовалась третья и седьмая модель.

EfficientNet хорошая модель, но сейчас есть и более новые и эффективные модели, например: <a href="https://colab.research.google.com/github/google/automl/blob/master/efficientnetv2/tfhub.ipynb">https://colab.research.google.com/github/google/automl/blob/master/efficientnetv2/tfhub.ipynb</a>

В другом варианте применялся метод ExponentialDecay для регулировки learning rate.

Хорошо, что он применялся, но его настройки были выбраны так, что LR практически занулялся уже после 3 эпох.

Архитектуры "голов" сознательно применялись разные.

Было бы неплохо увидеть таблицу сравнения разных голов и результатов обучения. Потому что по вашему коду не видно, что тестировались разные результаты. В ноутбуке только 2 варианта голов,

но при этом они применялись с разными архитектурами и поэтому результаты нельзя сравнивать напрямую.

▶ Можно сделать вывод, что модель с седьмой версией EfficientNetB7 (95,92%) существенно обгонит третью, если изменить показатель image\_size с 224 до 512.

Получается, что вы сделали сразу 2 изменения: изменили модель и изменили разрешение. Тогда непонятно что дало прирост: изменение разрешения или изменение модели.